

УНИВЕРЗИТЕТ У БЕОГРАДУ
МАТЕМАТИЧКИ ФАКУЛТЕТ



Филип Лазић

ОПТИМИЗАЦИЈА ЦЕЛОВИТОГ ПРОГРАМА
НА КОМПАЈЛЕРСКОЈ ИНФРАСТРУКТУРИ
LLVM

мастер рад

Београд, 2021.

Ментор:

др Иван ЧУКИЋ, редован професор
Универзитет у Београду, Математички факултет

Чланови комисије:

др Милена ВУЈОШЕВИЋ, ванредни професор
Универзитет у Београду, Математички факултет

др Саша МАЛКОВ, доцент
Универзитет у Београду, Математички факултет

Датум одбране: 15. јануар 2016.

Мами, тати и деду

Садржај

| | | |
|----------|---|-----------|
| 1 | Увод | 1 |
| 2 | LLVM компајлерска инфраструктура | 2 |
| 2.1 | LLVM међурепрезентација | 3 |
| 2.2 | LLVM компајлер | 4 |
| 2.3 | Предности LLVM-а | 6 |
| 3 | Оптимизација целовитог програма | 7 |
| 3.1 | Оптимизација током линковања | 7 |
| 4 | Закључак | 9 |
| | Литература | 10 |

Глава 1

Увод

Глава 2

LLVM компајлерска инфраструктура

LLVM(Low Level Virtual Machine[1]), упркос свом имену LLVM мало тога има са виртуелним машинама, то је колекција алата(компајлера, асемблера, дибагера, линкера) који су дизајнирани да буду компатибилни са постојећим алатима пре свега на Unix системима. Ови алати се могу користити за развој front-end-а за било који програмски језик, као и за развој back-end-а за сваку компјутерску архитектуру. LLVM је започет као истраживачки пројекат на Универзитету Илиноис са циљем да пружи статичку и динамичку компилацију програмских језика. Данас, LLVM садржи велики број подпројеката који се користе у великом обиму што у продукцијске што у истраживачке сврхе.

Неки од најбитнијих подпројеката су:

1. Језгро LLVM-а које садржи све потребне алате и библиотеке за конверзију међурепрезентације у објектне фајлове
2. Clang - front-end за C, C++ и Objective C програмске језике
3. libc++ - имплементација C++ стандардне библиотеке
4. LLDB - дибагер
5. LLD - линкер

2.1 LLVM међурепрезентација

LLVM међурепрезентација (LLVM IR[2]) базирана је на статичкој јединственој форми доделе(SSA[3]). Ова форма захтева да се свакој променљивој вредност додели тачно једном, као и да свака променљива буде дефинисана пре употребе. LLVM међурепрезентација је дизајнирана тако да подржи интерпроцедуралне оптимизације, анализу целог програма, агресивно реструктуирање програма итд. Веома битан аспект LLVM међурепрезентације је то што је она дефинисана као језик са јасно дефинисаном семантиком. Ова међурепрезентација се може користити у три различите форме:

1. текстуални асемблерски формат(.ll)
2. биткод формат (.bc)
3. унутар-меморијски формат

Овим се омогућавају ефикасне компајлерске трансформације и анализе, уз могућност визуалне анализе и дебаговања трансформација. Сва три формата су еквивалентна и лако се могу трансформисати један у други без губитка информација. У овом раду највише ћемо се фокусирати на текстуални формат и под међурепрезентацијом подразумевано ћемо мислити на овај формат, који се може окарактерисати као асемблерски језик независан од специфичне платформе.

Овде видимо две функције у програмском језику C које сабирају 2 броја.

```
unsigned add1(unsigned a, unsigned b) {
    return a+b;
}
// Rekurzivna funkcija za sabiranje 2 broja.
unsigned add2(unsigned a, unsigned b) {
    if (a == 0) return b;
    return add2(a-1, b+1);
}
```

Сада ћемо представити одговајући код у LLVM међурепрезентацији.

```
define i32 @add1(i32 %a, i32 %b) {
entry:
    %tmp1 = add i32 %a, %b
```

```
    ret i32 %tmp1
}

define i32 @add2(i32 %a, i32 %b) {
entry:
    %tmp1 = icmp eq i32 %a, 0
    br i1 %tmp1, label %done, label %recurse

recurse:
    %tmp2 = sub i32 %a, 1
    %tmp3 = add i32 %b, 1
    %tmp4 = call i32 @add2(i32 %tmp2, i32 %tmp3)
    ret i32 %tmp4

done:
    ret i32 %b
}
```

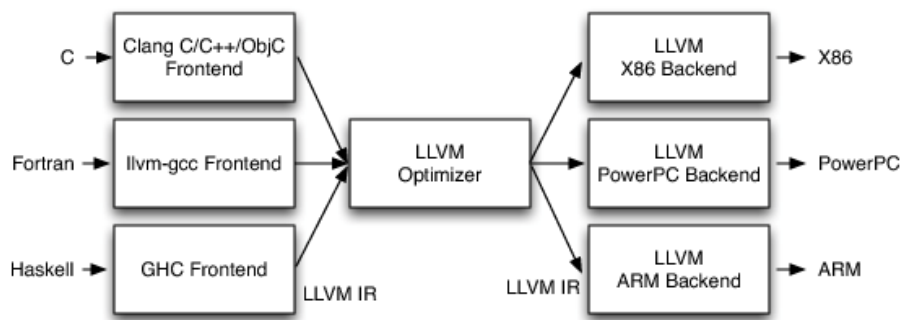
LLVM међурепрезентација је асемблерски формат сличан апстрактном RISC[4] скупу инструкција, са додатним структурама вишег нивоа.

Као што видимо у овом примеру, међурепрезентација подржава линеарне секвенце једноставних инструкција као што су сабирање, одузимање, гранање, упоређивање итд. Све ове инструкције су у тро-адресној форми, што значи да могу примити два регистра као улаз и резултат уписати у трећем регистру. Међурепрезентација је строго типизирана (на пример i32 означава тридесет-двобитни целобројни број), док се позив функције означава кључном речи call, а повратна вредност са ret. LLVM не користи фиксан број регистара, већ има бесконачан број променљивих које почињу карактером %. Функције и глобалне променљиве пре свог назива садрже карактер @. Унутар репрезентације постоје и лабеле, тело сваке функције почиње лабелом begin.

2.2 LLVM компајлер

Процес компилације у LLVM инфраструктури започиње у front-end делу који производи међурепрезентацију, која се затим шаље алату за оптимизацију који трансформише код кроз велики број оптимизација. Потом се трансфор-

мисани ко́д преводи у асемблерски ко́д на жељеној архитектури, и на крају се асемблерски ко́д преводи у машински. Овај процес, наравно поједностављен, можемо видети на слици испод.



Слика 2.1: LLVM процес компилације

Front-end

Front-end је задужен за парсирање, валидацију и проналазак грешака у изворном ко́ду, затим за превођење парсираног ко́да у LLVM међурепрезентацију. Превођење се обично извршава, прво изградњом AST-а[5], а затим и превођењем AST-а у међурепрезентацију. У суштини сваки програмски језик, уколико имплементира front-end који може да изгенерише LLVM међурепрезентацију, може користити алат за оптимизацију или back-end део LLVM-а. Постоји више пројеката који имплементирају LLVM front-end, али најбитнији су:

1. Clang - front-end за C, C++ и Objective C програмске језике
2. DragonEgg - GCC плагин који користи LLVM архитектуру за оптимизацију и и генерисање машинског кода

Алат за оптимизацију

Алат за оптимизацију (eng. optimizer[6]) дизајниран је тако да на улазу прима LLVM међурепрезентацију, изврши оптимизације над међурепрезентацијом и после тога генерише измењену међурепрезентацију, која би требало да се извршава брже. Овај алат је организован у више низова оптимизационих

пролаза, тако да је излаз једне оптимизације улаз у другу. Неки од примера оптимизационих пролаза су инлајновање, елиминација мртвог кода, реалокација израза, инваријација петљи итд. Од нивоа оптимизације зависе и оптимизациони пролази који ће бити покренути, на пример, у случају Clang-a, на нивоу -O0 нема оптимизација, док на нивоу -O3 покреће се свих 67 оптимизационих пролаза. Алат за оптимизацију се може покренути командом `opt`.

Back-end

LLVM back-end је фаза у којој се од међурепрезентације, која је улаз за ову фазу, генерише машински код за специфичну архитектуру. Главна компонента back-end-a је генератор кода (eng. LLVM code generator[7]) који користи сличан приступ као алат за оптимизацију, то јест дели генерисање машинског кода на мање пролазе, који имају за циљ генерисање најбољег могућег кода. Неки најбитнији пролази су бирање инструкција, алокација регистара, распоређивање (eng. scheduling). LLVM може генерисати код за велики број архитектура, неки од њих су: x86, ARM, PowerPC, SPARC.

2.3 Предности LLVM-a

LLVM пројекат је бесплатан и његов изворни код је у потпуности доступан, што је навело не само истраживаче са универзитета, већ и велики број компанија да учествују у његовом развоју, тако да данас значајан број људи активно учествује у одржавању и унапређивању овог пројекта. Модуларни дизајн омогућава лако мењање постојећих алата или додавање нових. Захваљујући овом дизајну врло лако је додати нови front-end, back-end или оптимизациони пролаз. Такође, LLVM подржава и:

1. JIT компилацију[8]
2. Clang-ов алат за статичку анализу кода (eng. static code analyzer[9]) - који служи за проналазак могућих грешака у коду
3. оптимизацију током линковања(LTO[10])

Очекује се да LLVM у потпуности замени GCC у блиској будућности.

Глава 3

Оптимизација целовитог програма


Обично изворни код програма делимо у више посебних фајлова(eng. source code). Компајлер чита фајл по фајл и за сваки генерише њему одговарајући објектни код, то јест сваком фајлу одговара један објектни код. Овако чинимо наш код читљивијим, омогућавамо паралелелно компајлирање више фајлова али и избегавамо потребу за компајлирањем целог програма за сваку промену у узворном коду. Овакав приступ има и лошу страну, пошто компајлер преводи фајл по фајл, он нема информације о коду који се налази у другим објектним фајловима. Због тога је немогуће извршити многе оптимизације, због тога што компајлер не може бити сигуран у семантичку еквивалентност. Овај проблем се може решити уз помоћ линкера, приступом познатијим као оптимизација током линковања(LTO).

3.1 Оптимизација током линковања

Захваљујући модуларном дизајну LLVM-а и чињеници да можемо компајлирати део кода, сачувати резултати и наставити компилацију касније без губитака информација слику 2.1 можемо проширити са линкером и оптимизацијама током овог процеса.

У наставку ћемо објаснити због чега је линкер користан у оптимизацији целовитог програма.

Главни задатак линкера је да све објектне фајлове споји у један фајл, извршни фајл или дељену библиотеку. Да би испунио овај задатак линкер прво мора да изврши реалокацију симбола и резолуцију симбола. Симболи могу бити глобалне променљиве, функције, класе итд. Сваки објектни фајл садржи та-



Слика 3.1: LLVM процес компилације са подршком линкера

белу симбола у којој се налазе сви симболи који могу бити дефинисани у истом објектном фајлу или у неком другом. Уколико симбол није дефинисан унутар објектног фајла он ће у табели симбола бити означен као „extern”, у супротном биће означен као „import”. Да би се успешно превео програм у извршни фајл, линкер мора да пронађе све недостајуће симболе у свим објектним фајловима и да упише њихове адресе (такође задатак линкера је да и неким импортованим симбола промени адресу, уколико је компајлер то назначио), то јесте да изврши резолуцију и реалокацију симбола. Због ових својстава линкер има круцијалну улогу у оптимизацији целовитог програма, јер има увид у све табеле симбола и алат за оптимизацију може то искористити за оптимизације делова кода који су му пре били „невидљиви”.

Глава 4

Закључак

Литература

- [1] LLVM Compiler Infrastructure – <https://llvm.org/docs/index.html>
- [2] LLVM Language Reference Manual – <https://llvm.org/docs/LangRef.html>
- [3] SSA Form – https://en.wikipedia.org/wiki/Static_single_assignment_form
- [4] RISC – https://en.wikipedia.org/wiki/Reduced_instruction_set_computer
- [5] Abstract Syntax tree – https://en.wikipedia.org/wiki/Abstract_syntax_tree
- [6] Optimizer – <https://llvm.org/docs/CommandGuide/opt.html>
- [7] LLVM Code Generator – <https://llvm.org/docs/CodeGenerator.html>
- [8] Just In Time Compilation – https://en.wikipedia.org/wiki/Just-in-time_compilation
- [9] Clang Static Code Analyzer – <https://clang-analyzer.llvm.org/>
- [10] Link Time Optimization – <https://llvm.org/docs/LinkTimeOptimization.html>